

# 《工程硕士数学》期末复习

## 第二章 解线性方程组的直接解法

### 1. Gauss消去法

- Gauss顺序消去法
  - 消去 ( $O(n^3)$ ) : 将  $Ax = b$  通过初等行变换化简为  $Ux = b$ .
    - 从第二行开始, 给每行乘以一个不同的系数  $l$ , 使得每行第一位都等于第一行第一位的相反数;
    - 从第二行开始, 给每行加上第一行, 使得每行第一位都等于0;
    - 从第三行开始, 给每行乘以一个不同的系数  $l$ , 使得每行第二位都等于第二行第二位的相反数;
    - 从第三行开始, 给每行加上第二行, 使得每行第二位都等于0;
    - .....
    - 最后得到上三角阵  $U$ .
  - 回代 ( $O(n^2)$ ) : 从最后一行开始逐行解  $Ux = b$ .
- Gauss列主元消去法 : 若消去到第  $k-1$  步 ( $k \geq 1$ ), 此时第  $k$  行及以下部分的第  $k$  位待消去, 则挑选所有这些数中绝对值最大的, 把它所在行换到第  $k$  行, 再消去。

$$\left[ \begin{array}{cccccc|c} a_{11}^{(1)} & a_{12}^{(1)} & \cdots & a_{1k}^{(1)} & \cdots & a_{1n}^{(1)} & b_1^{(1)} \\ & a_{22}^{(2)} & \cdots & a_{2k}^{(2)} & \cdots & a_{2n}^{(2)} & b_2^{(1)} \\ & & \ddots & \vdots & & \vdots & \vdots \\ & & & \boxed{a_{kk}^{(k)}} & \cdots & a_{kn}^{(k)} & b_k^{(k)} \\ & & & \vdots & & \vdots & \vdots \\ & & & a_{nk}^{(k)} & \cdots & a_{nn}^{(k)} & b_n^{(k)} \end{array} \right].$$

示例:

**例 2.2.4** 用列主元法解方程组  $Ax=b$ , 计算过程取五位数字, 其中

$$[A \mid b] = \left[ \begin{array}{ccc|c} -0.002 & 2 & 2 & 0.4 \\ 1 & 0.78125 & 0 & 1.3816 \\ 3.996 & 5.5625 & 4 & 7.4178 \end{array} \right].$$

这一题就需要先把3.996所在行换到第一行, 再进行第一次消去。

## 2. 顺序主子式

- **顺序主子式**：对 $n \times n$ 的方阵，求其左上角 $1 \times 1$ 、 $2 \times 2$ 、.....、 $n \times n$ 这 $n$ 个部分的行列式，这个过程称为求顺序主子式 $\Delta_1$ 、 $\Delta_2$ 、....、 $\Delta_n$ 。
- **Gauss消去法的可行性**：当顺序主子式任何一项都不为零时，方阵 $A$ 可以使用上述的Gauss消去。

## 3. LU分解

- **Doolittle分解（LU分解）**：通过Gauss消去法得到 $U$ 以后，一定能找到下三角阵 $L$ ，使 $A = LU$ 。
  - $L$ 的对角元素显然全为1。
- **Crout分解**：对换Doolittle分解中 $L$ 的对角元素和 $U$ 的对角元素，使得 $U$ 的对角元素全为1。
- **LDU分解**：提取Doolittle分解中 $U$ 的对角元素，形成对角矩阵 $D$ ，使得 $U$ 变成对角元素全为1的上三角阵 $\tilde{U}$ ，而此时 $A$ 可以分解为 $A = LD\tilde{U}$ 。
- **单位上（下）三角阵**：对角元素全为1的上（下）三角阵。
- **Doolittle分解的存在唯一性**：存在唯一Doolittle分解的条件为方阵 $A_{n \times n}$ 的顺序主子式 $\Delta_1$ 到 $\Delta_{n-1}$ 都不为零。
  - 显然，如果Doolittle分解存在且唯一，则Crout、LDU分解也都存在且唯一。

## 4. 三对角矩阵

- **三对角矩阵**：三对角矩阵是形如下图的方阵。

$$A = \begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{bmatrix}$$

- **三对角矩阵LU分解的形状**：三对角矩阵的LU分解一定形如下图。

$$L = \begin{bmatrix} 1 & & & & \\ l_2 & 1 & & & \\ & l_3 & 1 & & \\ & & \ddots & \ddots & \\ & & & l_n & 1 \end{bmatrix}, \quad U = \begin{bmatrix} u_1 & c_1 & & & \\ & u_2 & c_2 & & \\ & & \ddots & \ddots & \\ & & & c_{n-1} & \\ & & & & u_n \end{bmatrix}$$

- **追赶法**：
  - 先进行LU分解，使得 $LUx = b$ 。
  - 计算 $Ly = b$ ，此时有 $y = Ux$ 。
  - 计算 $Ux = y$ ，求出 $x$ 。

## 5. 正定矩阵的Cholesky分解

- **正定矩阵**：顺序主子式全部大于0的实对称方阵。
- **Cholesky分解**：对正定对称阵作LU分解，必有 $U = L^T$ 、 $A = LL^T$ 。这种分解称为Cholesky分解。
- **平方根法**（Cholesky法）：
  - 先进行Cholesky分解，使得 $LL^T x = b$ 。
  - 计算 $Ly = b$ ，此时有 $y = L^T x$ 。
  - 计算 $L^T x = y$ ，求出 $x$ 。

## 6. 范数

- **向量范数**：
  - **1-范数**：向量所有元素的和。
  - **2-范数**：向量模长。
  - **无穷范数**（ $\infty$ -范数）：向量所有元素的绝对值的最大值。
- **谱半径**：方阵 $A$ 的谱半径为其所有特征值的绝对值的最大值，记为 $\rho(A)$ 。
  - 回忆：特征多项式为 $\lambda I - A$ 的行列式计算结果，特征值为特征多项式的根。
- **矩阵范数**：
  - **1-范数**（列范数）：对所有元素取绝对值，再对每列进行求和。取最大的和为1-范数。
  - **2-范数**： $\sqrt{\rho(A^T A)}$ 。
    - 当 $A$ 为对称矩阵时，有 $\sqrt{\rho(A^T A)} = \sqrt{\rho(A^2)} = \rho(A)$ 。
  - **无穷范数**（ $\infty$ -范数、行范数）：对所有元素取绝对值，再对每行进行求和。取最大的和为无穷范数。

## 7. 条件数与病态

- **条件数**： $Cond(A)_n = \|A\|_n \|A^{-1}\|_n$ ，其中 $\|A\|$ 表示矩阵范数， $\|A\|_1$ 为1-范数， $\|A\|_2$ 为2-范数，.....。
  - 回忆：
    - 矩阵元素的代数余子式为 $B_{ij} = (-1)^{i+j} A_{ij}$ 。
    - 矩阵所有元素取代数余子式会得到伴随矩阵 $A^*$ ，而 $A^{-1} = \frac{1}{|A|} A^*$ 。
- **病态**：对病态矩阵 $A$ 的任意元素进行扰动（加减一个微小量），都会导致 $Ax = b$ 求解结果的巨大变化。
- **病态矩阵的判别**：当 $A$ 的任意一种条件数的数量级远大于 $A$ 的数量级时， $A$ 就是病态的。
- 比较可能出现病态的矩阵：
  - 各元素数量级差别很大的矩阵；
  - 进行列主元消去或LU分解时，发现主元也很小的矩阵；
  - 行列式很小的矩阵。

## 第三章 解线性方程组的迭代法

### 1. Jacobi、Gauss-Seidel法与SOR法

当矩阵 $A$ 满足下图所示形式时：

$$A = (a_{ij})_{n \times n} \in R^{n \times n}$$
$$A = D - L - U; D = \text{diag}[a_{11}, a_{22}, \dots, a_{nn}]$$

$$L = \begin{bmatrix} 0 & & & & \\ -a_{21} & 0 & & & \\ -a_{31} & -a_{32} & 0 & & \\ \vdots & & & \ddots & \\ -a_{n1} & -a_{n2} & & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & -a_{13} & \dots & -a_{1n} \\ & 0 & -a_{23} & & -a_{2n} \\ & & 0 & & \\ & & & \ddots & \\ & & & & 0 \end{bmatrix}$$

- **Jacobi法** :  $\begin{cases} B = D^{-1}(L + U) \\ x^{(k+1)} = Bx^{(k)} + D^{-1}b \end{cases}$ ;
- **Gauss-Seidel法** :  $\begin{cases} B = (D - L)^{-1}U \\ x^{(k+1)} = Bx^{(k)} + (D - L)^{-1}b \end{cases}$ ;
- **SOR法** :  $\begin{cases} B = L_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U] \\ x^{(k+1)} = L_\omega x^{(k)} + \omega(D - \omega L)^{-1}b \end{cases}$ , 式中 $\omega$ 为自主选择的松弛因子。
- **迭代矩阵** : 以上三式中的 $B$ 称为迭代矩阵。

### 2. 迭代法的收敛

- **迭代法的收敛性判定** :
  - 对任何迭代法, 若迭代矩阵 $B$ 满足 $\rho(B) < 1$ , 则迭代法收敛。
  - 若 $A$ 严格对角占优, 则无论用Jacobi法还是Gauss-Seidel法求解 $Ax = b$ , 均收敛。
    - 回忆: 若每行的对角元素绝对值均大于其他元素绝对值之和, 则这样的矩阵为严格对角占优矩阵。
    - 因此, 若 $Ax = b$ 无法直接用迭代法求解, 可以先进行行交换, 使 $A$ 为严格对角占优矩阵, 再求解。
  - 对任何对称正定矩阵 $A$ , Gauss-Seidel法收敛。
  - 对任何对称正定矩阵 $A$ , 若将非对角元素全部取相反数, 新矩阵仍然对称正定, 则Jacobi法收敛。
  - 对任何 $\omega \in (0, 2)$ , 有SOR法收敛。
    - 特别的,  $\omega < 1$ 称为低松弛,  $\omega > 1$ 为高松弛,  $\omega = 1$ 时SOR法退化回Gauss-Seidel法。
- **迭代法的渐进收敛速度** :  $R(B) = -\ln \rho(B) > 0$ 。  $\rho(B)$ 越小, 迭代法收敛越快。
  - **最佳松弛因子** : 对三对角对称正定矩阵, SOR法有最佳松弛因子  $\begin{cases} B_J = D^{-1}(L + U) \\ \omega_b = \frac{2}{1 + \sqrt{1 - \rho^2(B_J)}} \end{cases}$ 。
    - 此时有 $\rho(L_{\omega_b}) = \omega_b - 1$ 。
    - 当 $\omega \approx \omega_b$ 时, SOR法远快于Jacobi法。

### 3. 共轭梯度法

- **最速下降法** : 
$$\begin{cases} r^{(k)} = b - Ax^{(k)} \\ \alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ar^{(k)}, r^{(k)})} \\ x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)} \end{cases}。$$
- **共轭梯度法 (CG法)** : 
$$\begin{cases} \alpha_k = \frac{(r^{(k)}, r^{(k)})}{(Ap^{(k)}, p^{(k)})} \\ x^{(k+1)} = x^{(k)} + \alpha_k p^{(k)} \\ r^{(k+1)} = r^{(k)} - \alpha_k Ap^{(k)}, \text{ 初值可取 } \begin{cases} r^{(0)} = b - Ax^{(0)} \\ p^{(0)} = r^{(0)} \end{cases} \\ \beta_k = \frac{(r^{(k+1)}, r^{(k+1)})}{(r^{(k)}, r^{(k)})} \\ p^{(k+1)} = r^{(k+1)} + \beta_k p^{(k)} \end{cases}$$
  - CG法显著快于最速下降法和J法, 一般也显著快于SOR法。
  - CG法能保证对 $A_{n \times n}$ 最多只需 $n$ 步就求出精确解。

---

## 第四章 非线性方程的数值解法

### 1. 不动点迭代法

- **收敛** : 把方程化为 $x = f(x)$ 的形式, 若当 $\lim_{k \rightarrow +\infty} x_k = x^*$ , 则 $x^* = f(x^*)$ , 则此时不动点迭代法收敛。
- **不动点迭代法的整体收敛性** :
  - **映内性** : 若 $\forall x \in [a, b]$ 有 $f(x) \in [a, b]$ , 则 $[a, b]$ 中一定存在 $f(x)$ 的不动点。
  - **压缩性** : 在映内性满足的情况下, 若 $\exists L \in (0, 1)$ 使得 $|f(x) - f(y)| \leq L|x - y|$ 对任意 $x, y$ 成立, 则映内性所说的不动点是唯一的, 因此 $f(x)$ 确认能收敛到这个不动点。
  - **推论** : 在映内性满足的情况下, 若 $\exists L \in (0, 1)$ 使得 $|f'(x)| \leq L$ 对任意 $x \in [a, b]$ 成立, 则 $f(x)$ 也必然存在唯一的不动点, 从而收敛到这一不动点。
    - 显然, 一般使用推论证明整体收敛性, 不用压缩性证明。(参考第九章第1节“Lipschitz条件”)
- **不动点迭代法的局部收敛性** :
  - **局部收敛** : 若已有 $x^*$ , 且确认 $f'(x)$ 在 $x^*$ 附近的邻域内连续, 满足 $|f'(x^*)| < 1$ , 则不动点迭代法是局部收敛的。
  - **阶** : 给定式子 $\lim_{k \rightarrow +\infty} \frac{f^{(p)}(x^*)}{p!} \neq 0$ , 满足该式的最小正整数 $p$ 称为局部收敛阶数。
    - 显然, 计算阶数时可以忽略 $p!$ , 直接求 $f$ 在 $x^*$ 处的导数、二阶导数.....直到不等于0为止。

### 2. 不动点迭代法的加速方法

- **Aitken加速法** : 从迭代的第三项 $x_{k+2}$ 起进行修正: 
$$x_i = \frac{x_i x_{i-2} - x_{i-1}^2}{x_i + x_{i-2} - 2x_{i-1}}。$$

- **Steffensen加速法**：对于不动点迭代法 $x = \varphi(x)$ ，Steffensen加速法为：

$$\begin{cases} m = \varphi(x_k) \\ n = \varphi(m) \\ x_{k+1} = x_k - \frac{(m-n)^2}{n-2m+x_k} \end{cases}。$$

- Steffensen加速法至少能加速到二阶。
- Steffensen加速法有时能将不收敛的不动点迭代法加速为收敛。

### 3. Newton迭代法

- (带导数的) **Newton迭代法**： $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$ 。
  - 若要求的根为重根，则Newton迭代法是线性的。否则，Newton迭代法是至少二阶的。
- **不带导数的Newton迭代法**（割线法）： $x_{n+1} = x_n - f(x_n) \frac{(x_n - x_{n-1})}{f(x_n) - f(x_{n-1})}$ 。这个方法需要两个初值。
- **改进的Newton迭代法**： $x_{n+1} = x_n - m \frac{f(x_n)}{f'(x_n)}$ ，式中 $m$ 需要按照原方程情况进行指定。

## 第五章 矩阵特征值问题

本章讨论的矩阵特征值均用 $\lambda$ 表示，其中 $\lambda_1$ 是主特征值（最大的特征值），其余特征值按 $\lambda_2$ 、 $\lambda_3$ 、...、 $\lambda_n$ 从大到小排列。

### 1. 幂法

- **幂法**：对任给 $v_0$ ，有 $\begin{cases} z^{(k)} = Av^{(k-1)} \\ m^{(k)} = \max(z^{(k)}) \\ v^{(k)} = \frac{z^{(k)}}{m^{(k)}} \end{cases}$ ，其中 $m^{(k)}$ 收敛到主特征值 $\lambda_1$ ， $v^{(k)}$ 收敛到 $\lambda_1$ 对应的特征向量。
- **幂法的收敛速度**：用 $\frac{\lambda_2}{\lambda_1}$ 表示。 $\lambda_2$ 越接近 $\lambda_1$ ，收敛越慢。
- **幂法的Aitken加速**： $\overline{\lambda_1}^{(k)} = \frac{m_k m_{k+2} - m_{k+1}^2}{m_{k+2} - 2m_{k+1} + m_k}$ ，这个算法比 $m^{(k)}$ 收敛得更快。
- **逆幂法**： $\begin{cases} A'z^{(k)} = v^{(k-1)} \\ m^{(k)} = \max(z^{(k)}) \\ v^{(k)} = \frac{z^{(k)}}{m^{(k)}} \end{cases}$ ，其中第一步需要解方程， $m^{(k)}$ 收敛到最小特征值 $\lambda_n$ 的倒数， $v^{(k)}$ 收敛到 $\lambda_n$ 对应的特征向量。
  - **逆幂法的收敛速度**：用 $\frac{\lambda_n}{\lambda_{n-1}}$ 表示。 $\lambda_n$ 越接近 $\lambda_{n-1}$ ，收敛越慢。
- **原点位移的逆幂法**： $\begin{cases} (A' - qI)z^{(k)} = v^{(k-1)} \\ m^{(k)} = \max(z^{(k)}) \\ v^{(k)} = \frac{z^{(k)}}{m^{(k)}} \end{cases}$ ，其中第一步需要解方程。当 $q$ 最接近某一特征值 $\lambda_i$ 时， $m^{(k)}$ 收敛到 $\frac{1}{\lambda_i - q}$ ， $v^{(k)}$ 收敛到 $\lambda_i$ 对应的特征向量。
  - 若已知 $\lambda_i$ 对应的特征向量近似为 $x$ ，可直接取 $q = \frac{(Ax, x)}{(x, x)}$ 。

## 2. Householder矩阵的求法

- Householder矩阵：对任意 $n$ 维向量 $x$ ， $n$ 维向量 $v = [-\text{sgn}(x_1)\|x\|_2, 0, \dots, 0]^T$ ，总存在对称正交矩阵 $P$ ，使 $Px = v$ ，这样的矩阵 $P$ 称为Householder矩阵。
- Householder矩阵的求法：
 
$$\begin{cases} u = [x_1 + \text{sgn}(x_1)\|x\|_2, x_2, \dots, x_n]^T \\ \beta = \frac{1}{\|x\|_2^2 + |x_1| \cdot \|x\|_2} \\ P = I - \beta uu^T \end{cases}。$$
- 一般情况下的Householder矩阵：对任意 $n$ 维向量 $x$ ， $n$ 维向量 $v = (v_1, \dots, v_j = -\text{sgn}(x_j)\alpha, v_{j+1} = 0, \dots, v_k = 0, v_{k+1}, \dots, v_n)$ （相当于只有从第 $j+1$ 到 $k$ 项为0， $1 \leq j < k$ ， $j < k \leq n$ ），总存在对称正交矩阵 $P$ ，使 $Px = v$ 。这样的矩阵 $P$ 也称为Householder矩阵。
- 一般情况下的Householder矩阵求法：
 
$$\begin{cases} u = [0, \dots, 0, x_j + \text{sgn}(x_j)\alpha, x_{j+1}, \dots, x_k, 0, \dots, 0]^T \\ P = I - \frac{2uu^T}{\|u\|_2^2} \end{cases}$$
  - $\|u\|_2^2$ 的简便算法：
 
$$\begin{cases} \alpha = \sqrt{x_j^2 + x_{j+1}^2 + \dots + x_k^2} \\ \|u\|_2^2 = 2\alpha(\alpha + x_j) \end{cases}$$
  - 如此计算出的Householder矩阵 $P$ ，从 $j$ 行 $j$ 列到 $k$ 行 $k$ 列仍为Householder矩阵（记为 $\tilde{P}$ ），其余部分则为单位矩阵，如下图所示。

$$P = I - \frac{2uu^T}{\|u\|_2^2} = \begin{pmatrix} I_{j-1} & & \\ & \tilde{P} & \\ & & I_{n-k} \end{pmatrix}$$

- 等式右边为矩阵的Householder矩阵求法：当等式变为 $Px = V$ 时，若矩阵第一列 $v$ 仍满足上述的条件，则仍可按上述方法求取Householder矩阵 $P$ 。

## 3. 上Hessenberg矩阵的求法

- 上Hessenberg矩阵：次对角线以下元素均为0的矩阵，如下图所示。

$$B = \begin{bmatrix} * & * & \cdots & * & * \\ * & * & \cdots & * & * \\ & * & \cdots & * & * \\ & & \ddots & \vdots & \vdots \\ & & & * & * \end{bmatrix}。$$

- 上Hessenberg矩阵的求法：
  - 将待变换成上Hessenberg矩阵的矩阵 $A$ ，取第一列 $v_1$ ，寻找Householder矩阵 $P_1 v_1 = v'_1$ 使得 $v'_1$ 形如 $(*, *, 0, \dots, 0)^T$ 。
  - 计算 $H_1 = P_1 A P_1$ 。如 $H_1$ 还不是上Hessenberg矩阵，则除去 $A$ 最左上角的一行一列，对右下角的分块 $A_2$ ，取新的第一列 $v_2$ ，寻找 $n-1$ 维Householder矩阵 $P'_2 v_2 = v'_2$ 使得 $v'_2$ 形如 $(*, *, 0, \dots, 0)^T$ ，构造 $n$ 维Householder矩阵 $P_2 = \begin{bmatrix} I & \\ & P'_2 \end{bmatrix}$ 。
  - 计算 $H_2 = P_2 H_1 P_2$ 。如 $H_2$ 还不是上Hessenberg矩阵，则再除去 $A_2$ 最左上角的一行一列，对右下角的分块 $A_3$ ，取新的第一列 $v_3$ ，寻找 $n-2$ 维Householder矩阵 $P'_3 v_3 = v'_3$ 使得 $v'_3$ 形如 $(*, *, 0, \dots, 0)^T$ ，构造 $n$ 维矩阵 $P_3 = \begin{bmatrix} I & & \\ & P'_3 & \end{bmatrix}$ 。

- .....
- 直到  $H_k$  为上 Hessenberg 矩阵时，结束。

#### 4. QR分解

- **QR分解**：将非奇异矩阵  $A$  分解为  $A = QR$ ，其中  $Q$  为正交矩阵， $R$  为对角线均为正数的上三角阵。
- **QR分解方法**（类似于上 Hessenberg 矩阵的求法）：
  - 将待分解的矩阵  $A$ ，取第一列  $v_1$ ，寻找  $P_1 v_1 = v'_1$  使得  $v'_1$  形如  $(*, 0, \dots, 0)^T$ 。
  - 计算  $R_1 = P_1 A$ 。如  $R_1$  还不是上三角矩阵，则除去  $A$  最左上角的一行一列，对右下角的分块  $A_2$ ，取新的第一列  $v_2$ ，寻找  $n-1$  维矩阵  $P'_2 v_2 = v'_2$  使得  $v'_2$  形如  $(*, 0, \dots, 0)^T$ ，构造  $n$  维矩阵  $P_2 = \begin{bmatrix} I & \\ & P'_2 \end{bmatrix}$ 。
  - 计算  $R_2 = P_2 P_1 A$ 。如  $R_2$  还不是上三角矩阵，则除去  $A$  最左上角的一行一列，对右下角的分块  $A_3$ ，取新的第一列  $v_3$ ，寻找  $n-2$  维矩阵  $P'_3 v_3 = v'_3$  使得  $v'_3$  形如  $(*, 0, \dots, 0)^T$ ，构造  $n$  维矩阵  $P_3 = \begin{bmatrix} I & & \\ & P'_3 & \\ & & \ddots \end{bmatrix}$ 。
  - .....
  - 直到  $R_k = P_k P_{k-1} \dots P_1 A$  为上三角矩阵时，结束。此时有：
    - $Q = (P_1 P_2 \dots P_n)^{-1} = (P_1 P_2 \dots P_n)^T = P_k^T P_{k-1}^T \dots P_1^T$ 。
    - $R = P_k P_{k-1} \dots P_1 A$ 。
  - 有时希望对角线为正，因此需要取合适的对角矩阵  $D$ ，使  $\bar{Q} = QD$ 、 $\bar{R} = D^{-1}R$  对角线为正。

- 示例：求  $A = \begin{bmatrix} 1 & 1 & 1 \\ 2 & -1 & -1 \\ 2 & -4 & 5 \end{bmatrix}$  的 QR 分解，使  $Q$  和  $R$  对角线均为正。

- 解答：

- 先找到  $P$  使  $R = PA$  为上三角阵：
  - $k = -3, u = [4, 2, 2]^T, \beta = \frac{1}{12}$
  - $P = I - \beta u u^T = \begin{bmatrix} -\frac{1}{3} & -\frac{2}{3} & -\frac{2}{3} \\ -\frac{2}{3} & \frac{2}{3} & -\frac{1}{3} \\ -\frac{2}{3} & -\frac{1}{3} & \frac{2}{3} \end{bmatrix}$ ，此时  $PA = \begin{bmatrix} -3 & 3 & -3 \\ 0 & 0 & -3 \\ 0 & -3 & 3 \end{bmatrix}$ 。
  - 注意到第二列对角线以下仍然不是 0，因此再对  $A_0 = \begin{bmatrix} 0 & -3 \\ -3 & 3 \end{bmatrix}$  找  $P_0$ ，使  $R_0 = P_0 A_0$  为上三角阵。
    - $k_0 = -3, u_0 = [3, -3]^T, \beta_0 = \frac{1}{9}$ 。
    - $P_0 = I - \beta_0 u_0 u_0^T = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ ，此时  $P_0 A_0 = \begin{bmatrix} -3 & 3 \\ 0 & -3 \end{bmatrix}$ 。
  - 于是取  $P_1 = \begin{bmatrix} 1 & & \\ & P_0 & \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}$ ，此时：



$$\blacksquare R = P_1 * P * A = \begin{bmatrix} -3 & 3 & -3 \\ 0 & -3 & 3 \\ 0 & 0 & -3 \end{bmatrix}。$$

$$\blacksquare Q = \begin{bmatrix} -\frac{1}{3} & -\frac{2}{3} & -\frac{2}{3} \\ -\frac{2}{3} & -\frac{1}{3} & \frac{2}{3} \\ -\frac{2}{3} & \frac{2}{3} & -\frac{1}{3} \end{bmatrix}。$$

但这是对角线非正的。因此取  $\bar{D} = \text{diag}(-1, -1, -1)$ ：

$$\blacksquare \bar{Q} = Q\bar{D} = \begin{bmatrix} \frac{1}{3} & \frac{2}{3} & \frac{2}{3} \\ \frac{2}{3} & \frac{1}{3} & -\frac{2}{3} \\ \frac{2}{3} & -\frac{2}{3} & \frac{1}{3} \end{bmatrix}。$$

$$\blacksquare \bar{R} = \bar{D}^{-1}R = \begin{bmatrix} 3 & -3 & 3 \\ 0 & 3 & -3 \\ 0 & 0 & 3 \end{bmatrix}。$$

检验得  $\bar{Q}\bar{R} = A$ ，符合题意。

- 基本QR迭代方法： $\begin{cases} A_k = Q_k R_k \\ A_{k+1} = R_k Q_k \end{cases}$ ，该法中  $A_k$  会收敛与上三角阵，对角元素为  $A$  特征值。

## 第六章 插值法

### 1. Lagrange插值

- $n$ 次Lagrange插值多项式： $L_n(x) = \sum_{k=0}^n f(x_k) [\prod_{j=0, j \neq k}^n (\frac{x-x_j}{x_k-x_j})]$ 。
  - 显然， $n$ 次Lagrange插值多项式是 $n$ 次多项式，对应 $n-1$ 个插值点，在这些插值点上  $L_n(x) = f(x)$ 。


## 第七章 函数逼近

## 第八章 数值积分


本章讨论的数值积分均形如  $I(f) = \int_a^b f(x)dx \approx \int_a^b L_1(x)dx$ 。

### 1. Newton-Cotes型数值积分

- 插值型公式：设对  $f(x)$  进行 $n$ 次Lagrange插值，得到插值多项式  $L_n(x) = \sum_{k=0}^n f(x_k) [\prod_{j=0, j \neq k}^n (\frac{x-x_j}{x_k-x_j})]$ ，则插值型公式定义为  $I(f) \approx \sum_{k=0}^n f(x_k) [\prod_{j=0, j \neq k}^n (\frac{x_k-x_j}{x_k-x_j})]$ 。
  - 下述的梯形、Simpson、Newton-Cotes求积公式，事实上全部为插值型公式。
- 代数精度：若某个插值型求积公式  $I(f) \approx \int_a^b L_1(x)dx$  能在  $f(x) = 1, x, x^2, \dots, x^p$  严格取等，而在  $f(x) = x^{p+1}$  只能取约等，则该求积公式的代数精度为 $p$ 次。
- 梯形公式： $I(f) \approx \frac{b-a}{2} [f(a) + f(b)]$ ，如下图所示。



- 梯形公式的代数精度：1。
- Simpson公式： $I(f) = \frac{b-a}{6} [f(a) + f(b) + 4f(\frac{b+a}{2})]$ ，如下图所示。



- Simpson公式的代数精度：3。
- Newton-Cotes求积公式： $I(f) \approx (b-a) \sum_{k=0}^n C_k^{(n)} f(x_k)$ ，其中 $C_k^{(n)}$ 的值见下表。

$n$	$C_k^{(n)}$				
1	$\frac{1}{2}$				
2	$\frac{1}{6}$	$\frac{4}{6}$			
3	$\frac{1}{8}$	$\frac{3}{8}$			
4	$\frac{7}{90}$	$\frac{16}{45}$	$\frac{2}{15}$		
5	$\frac{19}{288}$	$\frac{25}{96}$	$\frac{25}{144}$		
6	$\frac{41}{840}$	$\frac{9}{35}$	$\frac{9}{280}$	$\frac{34}{105}$	
7	$\frac{751}{17\ 280}$	$\frac{3577}{17\ 280}$	$\frac{1323}{17\ 280}$	$\frac{2989}{17\ 280}$	
8	$\frac{989}{28\ 350}$	$\frac{5888}{28\ 350}$	$-\frac{928}{28\ 350}$	$\frac{10\ 496}{28\ 350}$	$-\frac{4540}{28\ 350}$

- $C_k^{(n)}$  满足  $C_k^{(n)} = C_n^{(n-k)}$ 。
- $\{x_0 = a, x_1, \dots, x_n = b\}$  等分了区间  $[a, b]$ 。
- $n = 1$  时, Newton-Cotes 求积公式退化为梯形公式;  $n = 2$  时退化为 Simpson 公式,  $n = 3$  时称为 Simpson 3/8 公式;  $n = 4$  时称为 Boole 公式 (或 Cotes 公式)。
- **Newton-Cotes 求积公式的稳定性**:  $n \leq 7$  的 Newton-Cotes 都是稳定的, 因为此时所有的  $C'$  均为正数。
- **开型 Newton-Cotes 求积公式**: 即令  $\{a, x_0, x_1, \dots, x_n, b\}$  等分  $[a, b]$  的 Newton-Cotes 公式。
  - **中点公式**: 取  $n = 0$ , 有  $I(f) \approx (b - a)f(\frac{a+b}{2})$ 。
  - **两点公式**: 取  $n = 1$ , 有  $I(f) \approx \frac{b-a}{2}[f(x_0) + f(x_1)]$ 。
  - **三点公式**: 取  $n = 2$ , 有  $I(f) \approx \frac{b-a}{3}[2f(x_0) - f(x_1) + 2f(x_2)]$ 。

## 2. 复合求积公式

- **复合梯形公式**: 将  $[a, b]$  等分为  $\{x_0 = a, x_1, \dots, x_n = b\}$ , 并对每个部分使用梯形公式求积分, 得到  $I_n(f) \approx \frac{b-a}{2n}[f(a) + 2\sum_{k=1}^{n-1} f(x_k) + f(b)]$ , 即为复合梯形公式。
- **复合 Simpson 公式**: 将  $[a, b]$  等分为  $\{x_0 = a, x_1, \dots, x_n = b\}$ , 并对每个部分使用 Simpson 公式求积分, 得到  $I_n(f) \approx \frac{b-a}{6n}[f(a) + 2\sum_{k=1}^{n-1} f(x_k) + f(b) + 4\sum_{k=1}^n f(\frac{x_k+x_{k-1}}{2})]$ , 即为复合 Simpson 公式。
- **Romberg 算法**:
  1.  $h = b - a$ ,  $T(0, 0) = \frac{h}{2}(f(a) + f(b))$ , 转 2。
  2. 将区间  $[a, b]$  分半,  $T(1, 0) = I_2(f)$ ,  $T(1, 1) = \frac{4T(1, 0) - T(0, 0)}{4^1 - 1}$ ,  $1 \rightarrow j$ , 转 4。
  3. 对区间作  $2^j$  等分,  $T(j, 0) = I_{2^j}(f)$ ,  $T(j, k) = \frac{4^k T(j, k-1) - T(j-1, k-1)}{4^k - 1}$ ,  $k = 1, 2, \dots, j$ , 求出  $T(j, j)$ , 转 4。
  4.  $|T(j, j) - T(j-1, j-1)| < \varepsilon$ , 则  $T(j, j)$  即为所求; 否则  $j + 1 \rightarrow j$ , 转 3。
  - 式中  $I_n(f)$  使用复合梯形公式求解。
  - Romberg 算法的计算结果可以打印为  $T$ -表, 如下表所示。

$T(0,0)$				
$T(1,0)$	$T(1,1)$			
$T(2,0)$	$T(2,1)$	$T(2,2)$		
$T(3,0)$	$T(3,1)$	$T(3,2)$	$T(3,3)$	
...	...	...	...	...

## 3. Gauss 型求积公式

- **最高精度**: 对于有  $n + 1$  个节点的求积公式, 其最高代数精度为  $2n + 1$ 。
- **Gauss 型求积公式**: 达到了最高代数精度的求积公式。
- **Gauss 型求积公式的求法**: 若有 Gauss 型求积公式  $I(f) = \int_a^b \rho(x)f(x)dx$ , 希望使用  $n + 1$  个节点得到  $2n + 1$  精度, 则求法如下:

- $\phi(x) = x^{n+1} + ax^n + bx^{n-1} + \cdots + z$ , 则联立
 
$$\begin{cases} \int_a^b \rho(x)\phi(x)dx - 0 \\ \int_a^b x\rho(x)\phi(x)dx - 0 \\ \cdots \\ \int_a^b x^n\rho(x)\phi(x)dx - 0 \end{cases}$$
, 由此解出  $a, b, \cdots, z$ .

- 解  $\phi(x) = 0$ , 得到  $x_1, x_2, \cdots, x_{n+1}$  共  $n+1$  个解, 于是知  $I(f) = \int_a^b \rho(x)f(x)dx \approx \sum_{k=1}^{n+1} A_k f(x_k)$ .
- 由于精度为  $2n+1$ , 则显然可以根据代数精度的求法, 令  $I(f)$  在  $f(x) = 1, x, \cdots, x_n$  严格取等, 解出  $A_1, A_2, \cdots, A_{n+1}$ . 此时即有 Gauss 型求积公式  $I(f) \approx \sum_{k=1}^{n+1} A_k f(x_k)$ .
- 从以上过程中可以看出, 只要给定求积区间  $[a, b]$  和权函数  $\rho(x)$ , 则不论对于什么样的  $f(x)$ , 都能解出唯一一组  $\{A_k\}$ , 使得  $I(f) \approx \sum_{k=1}^{n+1} A_k f(x_k)$ .
- 示例:

### 例 8.5.2 确定求积公式

$$\int_0^1 \sqrt{x} f(x) dx \approx A_0 f(x_0) + A_1 f(x_1)$$

中的系数  $A_0, A_1$  及节点  $x_0, x_1$ , 使该求积公式具有最高代数精度.

**解** 具有最高代数精度的求积公式为 Gauss 求积公式. 节点  $x_0, x_1$  为  $[a, b] = [0, 1]$  上以权函数  $\rho(x) = \sqrt{x}$  的两次正交多项式的零点. 不妨假定  $\phi_2(x)$  的首项系数为 1 (不改变零点).

设  $\phi_2(x) = x^2 + ax + b$ , 如果有

$$\int_0^1 \sqrt{x} \phi_2(x) dx = 0, \quad \int_0^1 \sqrt{x} \cdot x \phi_2(x) dx = 0, \quad (8.5.8)$$

那么  $\phi_2(x)$  在  $[0, 1]$  上以权函数  $\rho(x) = \sqrt{x}$  与零次和一次多项式正交. 所以  $\phi_2(x)$  是  $[a, b]$  上, 以权函数  $\rho(x) = \sqrt{x}$  的二次正交多项式 (首项系数为 1).

由 (8.5.8) 式得出  $a = -\frac{10}{9}, b = \frac{5}{21}$ , 从而得出

$$\phi_2(x) = x^2 - \frac{10}{9}x + \frac{5}{21}.$$

解  $\phi_2(x) = 0$ , 有

$$x_0 = \frac{35 - 2\sqrt{70}}{63}, \quad x_1 = \frac{35 + 2\sqrt{70}}{63},$$

即  $x_0 = 0.289\,949, x_1 = 0.821\,162$ .

由于两个节点的 Gauss 求积公式具有 3 次代数精度, 因此对于  $f(x) = 1, x$ , 求积公式准确成立. 即

$$\begin{aligned} f(x) = 1, \quad & \text{有} \quad \int_0^1 \sqrt{x} dx = A_0 + A_1, \\ f(x) = x, \quad & \text{有} \quad \int_0^1 \sqrt{x} \cdot x dx = A_0 x_0 + A_1 x_1. \end{aligned}$$

定积分计算后得

$$A_0 + A_1 = \frac{2}{3}, \quad x_0 A_0 + x_1 A_1 = \frac{2}{5}.$$

由此解得  $A_0 = 0.277\,556, A_1 = 0.389\,111$ . 求积公式为

$$\int_0^1 \sqrt{x} f(x) dx \approx 0.277\,556 f(0.289\,949) + 0.389\,111 f(0.821\,162).$$

- Gauss-Legendre 求积公式**:  $\int_{-1}^1 f(x) dx = \sum_{k=0}^n A_k f(x_k)$ , 式中对不同的  $n$  有不同的  $A_k$ , 如下图所示.

表 8.4

$n$	$x_k$	$A_k$	$n$	$x_k$	$A_k$
0	0	2	5	$\pm 0.932\ 469\ 514\ 2$	0.171 324 492 4
1	$\pm 0.577\ 350\ 269\ 2$	1		$\pm 0.661\ 209\ 386\ 5$	0.360 761 573 0
2	$\pm 0.774\ 596\ 669\ 2$	0.555 555 555 6		$\pm 0.238\ 619\ 186\ 1$	0.467 913 934 6
	0	0.888 888 888 9	6	$\pm 0.949\ 107\ 912\ 3$	0.129 484 966 2
3	$\pm 0.861\ 136\ 311\ 6$	0.347 854 845 1		$\pm 0.741\ 531\ 185\ 6$	0.279 705 391 5
	$\pm 0.339\ 981\ 043\ 6$	0.652 145 154 9		$\pm 0.405\ 845\ 151\ 4$	0.381 830 050 5
4	$\pm 0.906\ 179\ 845\ 9$	0.236 926 885 1		0	0.417 959 183 7
	$\pm 0.538\ 469\ 310\ 1$	0.478 628 670 5	7	$\pm 0.960\ 289\ 856\ 5$	0.101 228 536 3
	0	0.568 888 888 9		$\pm 0.796\ 666\ 477\ 4$	0.222 381 034 5
				$\pm 0.525\ 532\ 409\ 9$	0.313 706 645 9
				$\pm 0.183\ 434\ 642\ 5$	0.362 683 783 4

- 当求积区间不为 $[-1, 1]$ 而为 $[a, b]$ 时, 应将 $x$ 变换为 $t = \frac{2x-b-a}{b-a}$ , 将 $\int_a^b f(x)dx$ 变为 $\frac{b-a}{2} \int_{-1}^1 f(t)dt$ 。
- Gauss-Chebyshev求积公式:  $\int_{-1}^1 \frac{f(x)}{\sqrt{1-x^2}} dx = \sum_{k=0}^n \frac{\pi}{n+1} f(\cos(\frac{2k+1}{2n+2}\pi))$ 。
- 类似地, 当求积区间不为 $[-1, 1]$ 而为 $[a, b]$ 时, 应将 $x$ 变换为 $t = \frac{2x-b-a}{b-a}$ 。

## 第九章 常微分方程数值解法

本章讨论的常微分方程均形如 $\begin{cases} y' = f(x, y) \\ y_0 = \alpha \end{cases}$ , 迭代步长一律为 $h$ , 即 $x_k = x_0 + kh$ 。

### 1. Lipschitz条件

- Lipschitz条件: 若存在常数 $L$ 使任意 $y_1, y_2$ 满足 $|f(y_1) - f(y_2)| \leq L(y_1 - y_2)$ , 则 $f$ 满足Lipschitz条件。
- 加强的判别条件:  $\forall (x, y)$ 满足 $|\frac{\partial f}{\partial y}(x, y)| \leq L$ 的函数 $f(x, y)$ 一定对 $y$ 满足Lipschitz条件。
  - 这个条件是充分不必要条件, 反推不一定成立。

### 2. 一阶单步方法

- Euler法
  - 显式Euler法:  $\begin{cases} y_{n+1} = y_n + hf(x_n, y_n) \\ y_0 = \alpha \end{cases}$ ;
  - 隐式Euler法:  $\begin{cases} y_{n+1} = y_n + hf(x_{n+1}, y_{n+1}) \\ y_0 = \alpha \end{cases}$ ; 这个方法在给定 $y_n$ 时并不能直接求解 $y_{n+1}$ , 而是还要解方程, 因此一般在近似解 $y_n$ 已知时使用。
  - Euler法的收敛性: 若能找到使 $f$ 对 $y$ 满足Lipschitz条件的 $L$ , 则 $h < \frac{1}{L}$ 可使Euler法收敛。
- 梯形方法
  - $\begin{cases} y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_{n+1})] \\ y_0 = \alpha \end{cases}$ , 即对显式、隐式Euler方法做了折中。
  - 梯形方法的收敛性: 若能找到使 $f$ 对 $y$ 满足Lipschitz条件的 $L$ , 则 $h < \frac{2}{L}$ 可使梯形方法收敛。

- 梯形方法比显式Euler法一般更快。
- 预估-校正方法
  - 改进Euler法:  $\begin{cases} y_{n+1} = y_n + \frac{h}{2}[f(x_n, y_n) + f(x_{n+1}, y_n + hf(x_n, y_n))] \\ y_0 = \alpha \end{cases}$ 。
  - 改进Euler法比显式Euler法一般更精确。
- 中点公式:  $\begin{cases} y_{n+1} = y_n + h(f(x_n + \frac{h}{2}, y_n + \frac{h}{2}f(x_n, y_n))) \\ y_0 = \alpha \end{cases}$

### 3. 截断误差

- 局部截断误差: 对方法  $\sum_{k=0}^p y_{n+k} = \sum_{k=0}^q y'_{n+k}$  中的每项进行Taylor展开, 得到的式子  $T_{n+1} = \sum_{i=0}^{+\infty} \beta h^i y_n^{(i)}$  即为局部截断误差。
  - 此处所用的Taylor展开公式:  $\begin{cases} y_{n+k} = y(x + kh) = \sum_{i=0}^{+\infty} \frac{(kh)^i}{i!} y_n^{(i)} \\ y'_{n+k} = f(x + kh) = \sum_{i=0}^{+\infty} \frac{(kh)^i}{i!} y_n^{(i+1)} \end{cases}$
- 主局部截断误差:  $T_{n+1}$  的前面几项往往是0。对第一个非零项, 称之为主局部截断误差。
- 阶: 取主局部截断误差中  $h$  的次数  $p$ , 有  $p - 1$  为该方法的阶。

### 4. 相容性、收敛性与绝对稳定性

- 相容性、收敛性: 若显式单步法的阶数  $\geq 1$ , 则它具有相容性。若它相容, 则还具有收敛性。
- 绝对稳定性: 取  $y'(x) = f(x, y) = \lambda y$ , 则单步法可以写成  $y_{n+1} = E(\lambda h)y_n$ 。
  - 绝对稳定性的判别方法: 令  $\lambda h$  满足  $|E(\lambda h)| < 1$  即可。
  - 当显式单步法中的  $f$  不是  $f(x, y)$  而是  $f(g(x), h(y))$  时, 则  $\lambda y$  变成  $\lambda h(y)$ 。