

《网络测量与分析技术》

软硕231 王泽文

软硕232 丁浩然

选取论文

Jie You, Jae-Won Chung, & Mosharaf Chowdhury. (2022). Zeus: Understanding and Optimizing GPU Energy Consumption of DNN Training.

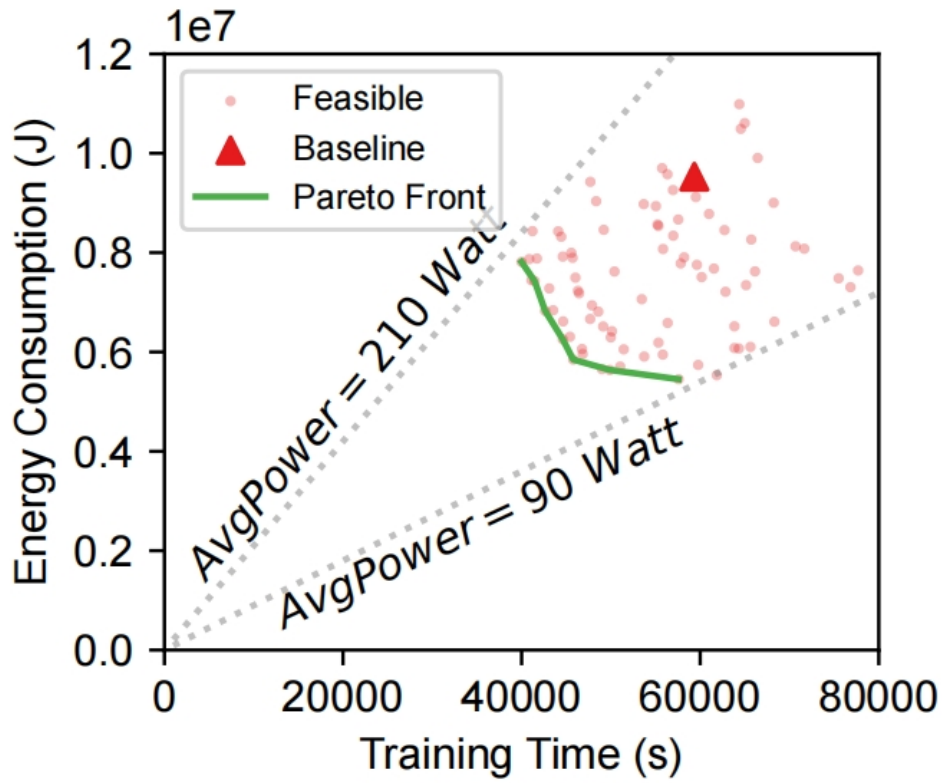
Survey

背景

DNN网络的训练目前已经被大量使用在数据驱动领域中，比如计算机视觉、自然语言处理、个性化推荐、语音识别等等。为了满足DNN网络对计算量的需求，人们主要使用可以高度并行并且性能不断增强的GPU来进行训练。

然而，随着对计算量的需求不断增大，训练所消耗的能量也不断增大。比如说，训练GPT-3模型可以消耗1287MWh，相当于120年的美国住宅平均用电量。这个势头甚至还在不断增长，但是现有的大部分DNN训练研究都忽略了能量消耗这一问题。

为了评估能量消耗与训练时间的关系，作者记录同一训练任务达到同一精度时所需的能量与时间，通过调整batch size与power limit进行了许多组实验，每组实验的结果作为能量-时间图上的一个点，绘制出了以下的图。



(a) Energy-Time Tradeoff

作者通过能量-时间的帕累托边界进行分析，发现了两个现象：1.所有帕累托最优的训练配置会比盲目使用最大batch size以及GPU power limit的配置消耗更少能量；2.训练时间与能量消耗之间存在一种权衡关系，想要优化能量消耗就必然会牺牲一定的训练时间。于是作者希望能设计出一种可以自动调整训练时间与能量消耗之间权衡关系的方法。

方法

作者提出了一种名为Zeus的框架，可以在线即时对训练任务进行优化。其工作流程如下：1.用户上传训练任务以及可以实现的batch size以及power limit；2.Zeus通过过去的执行历史来预测优化方案；3.将这个方案应用在训练任务上；4.收集训练过程的数据，包括准确率以及能量消耗等，将这些数据重新提交给Zeus，让它从这些数据中持续学习并且改变内部状态。

算法部分，作者首先定义了两个重要变量：ETA（模型到达某一精度时的能量消耗）以及TTA（模型到达某一精度时的训练时间）。随后又给出一个很简单的代价函数 $C(b, p; \eta) = \eta ETA(b, p) + (1 - \eta) MAXPOWER * TTA(b, p)$ ，用 η 来控制对ETA与TTA的权衡。在对该函数进行一系列变换后，变为如下形式：

$$\begin{aligned}
 C(b, p; \eta) &= (\eta \cdot AvgPower(b, p) + (1 - \eta) \cdot MAXPOWER) \cdot TTA(b, p) \\
 &= Epochs(b) \cdot \frac{\eta \cdot AvgPower(b, p) + (1 - \eta) \cdot MAXPOWER}{Throughput(b, p)}
 \end{aligned}$$

在这个式子中，AvgPower与Throughput在batch size给定的情况下，可以通过遍历power limit快速收集得到，而Epochs又与power limit无关，因此可以将该问题简化为先确定batch size，再根据固定的batch size确定power limit。

确定power limit的方法比较简单，对于一个没有被计算过的batch size，在一个epoch中分出许多切片，每个切片尝试不同的power limit并收集AvgPower与Throughput，通过上述公式确定最优power limit并进行记录，以后再遇到相同batch size直接使用该power limit。

batch size的确定则更加复杂。由于相比power limit，batch size对各项的影响具有不确定性，因此作者将其抽象为一个MAB模型。每次从所有batch size的损耗函数的后验分布中抽样出一个值，然后选取最小的值对应的batch size。

Input: Batch sizes \mathcal{B}

Belief posterior parameters $\hat{\mu}_b$ and $\hat{\sigma}_b^2$

Output: Batch size to run b^*

Function Predict ($\mathcal{B}, \hat{\mu}_b, \hat{\sigma}_b^2$):

```

1  | foreach batch size  $b \in \mathcal{B}$  do
   |   /* Sample from the belief distribution */
2  |   Sample  $\hat{\theta}_b \sim \mathcal{N}(\hat{\mu}_b, \hat{\sigma}_b^2)$ 
3  | end
   |   /* Select the arm with smallest mean cost sample */
4  |  $b^* \leftarrow \operatorname{argmin}_b \hat{\theta}_b$ 

```

Algorithm 1: Gaussian Thompson Sampling: Choosing the next batch size to run (Predict)

之后在执行一段时间后需要根据这段时间任务执行收集的数据来反馈给本次batch size对应的后验分布。

Input: Batch size b and observed cost C

Previous cost observations C_b for b

Belief prior parameters $\hat{\mu}_0$ and $\hat{\sigma}_0^2$

Output: Belief posterior parameters $\hat{\mu}_b$ and $\hat{\sigma}_b^2$


Function `Observe($b, C, C_b, \hat{\mu}_0, \hat{\sigma}_0^2$)`:

```
/* Add the most recent cost observation to history */
1   $C_b \leftarrow C_b \cup \{C\}$ 
/* Compute the variance of the cost */
2   $\tilde{\sigma}^2 \leftarrow \text{Var}(C_b)$ 
/* Compute the belief distribution's posterior variance */
3   $\hat{\sigma}_b^2 \leftarrow \left( \frac{1}{\hat{\sigma}_0^2} + \frac{|C_b|}{\tilde{\sigma}^2} \right)^{-1}$ 
/* Compute the belief distribution's posterior mean */
4   $\hat{\mu}_b \leftarrow \hat{\sigma}_b^2 \left( \frac{\hat{\mu}_0}{\hat{\sigma}_0^2} + \frac{\text{Sum}(C_b)}{\tilde{\sigma}^2} \right)$ 
```

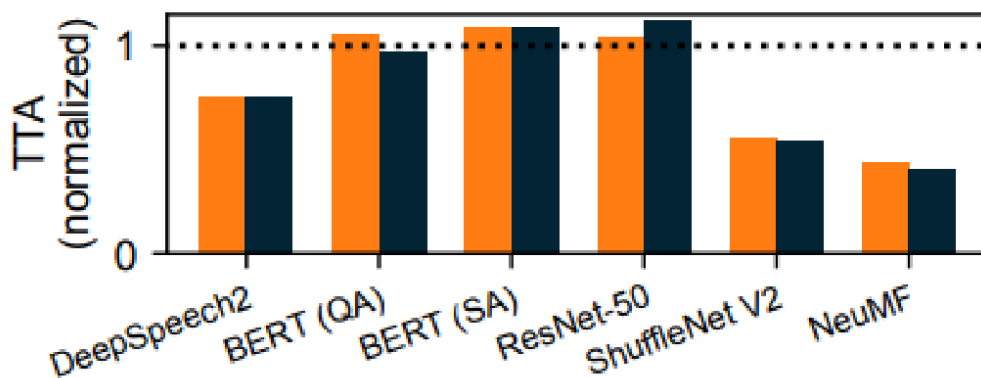
Algorithm 2: Gaussian Thompson Sampling: Updating the belief distribution (Observe)

此外，还需要进行一些额外的优化，比如算法本身的开销如果大于计算出的训练开销的一定比例时，需要停止算法；在选择batch size时需要提前进行一些剪枝，尽量选择更小的batch size。

结果



(a) *Energy Consumption*



(b) Training Time

从作者给出的结果柱状图中可以看出，Zeus总体来说在能量消耗上对比baseline有较大提升，在部分任务上对比grid search也有一定提升。

Proposal

Project主题

复现Zeus系统，并在可提供的硬件条件下测试Zeus对DNN网络训练功耗的优化效果。

目标

按照论文描述，Zeus系统能够对各种场景下的DNN网络训练达到15.3% - 75.8%的GPU功耗优化效果，同时能降低60.1%的训练时间。我们的目标是在完成复现后尽量达到类似的优化效果；如最终与论文给出的优化效果有差异，则进一步总结差异出现的原因。

GPU功耗（ETA）的计算公式为： $ETA = TTA * GPU\text{平均功率}$ ，式中TTA为DNN网络训练至指定 accuracy所需的时间，即 $TTA = \text{Epoch numbers} / \text{Epoch numbers per second (Throughput)}$ 。该公式计算过程中需保持batch size、GPU功率上限和指定的accuracy为不变量。

计划

- 理解论文中Zeus系统的算法和架构，并进行复现。
- 测试Zeus对各种场景下的DNN网络训练（例如NLP、推荐算法、语音/图像识别等等）的功耗优化效果，包括ETA优化效果和训练时间缩短效果。
- （如发现与论文中给出的优化情况有差异）总结差异出现的原因。

时间安排

时间	安排
第3周	阅读论文，撰写survey和proposal
第4-6周	理解并复现Zeus系统的算法和架构
第7-8周	对复现的系统进行测试，并完成总结与汇报

